


大模型微调：Fine-tuning三种微调方式


Supervised Fine-tuning



在生成式AI和大语言大模型（如GPT、LLaMA）的广泛应用中，微调（Fine-tuning）作为模型适应特定任务的关键步骤，其重要性不言而喻。以下将详细介绍三种流行的微调方式：Prompt-tuning、Prefix-tuning和LoRA，深入理解每种方法的原理、特点及应用场景。

Fine-tune Example:

Learn a Specific Style of Answering and Writing

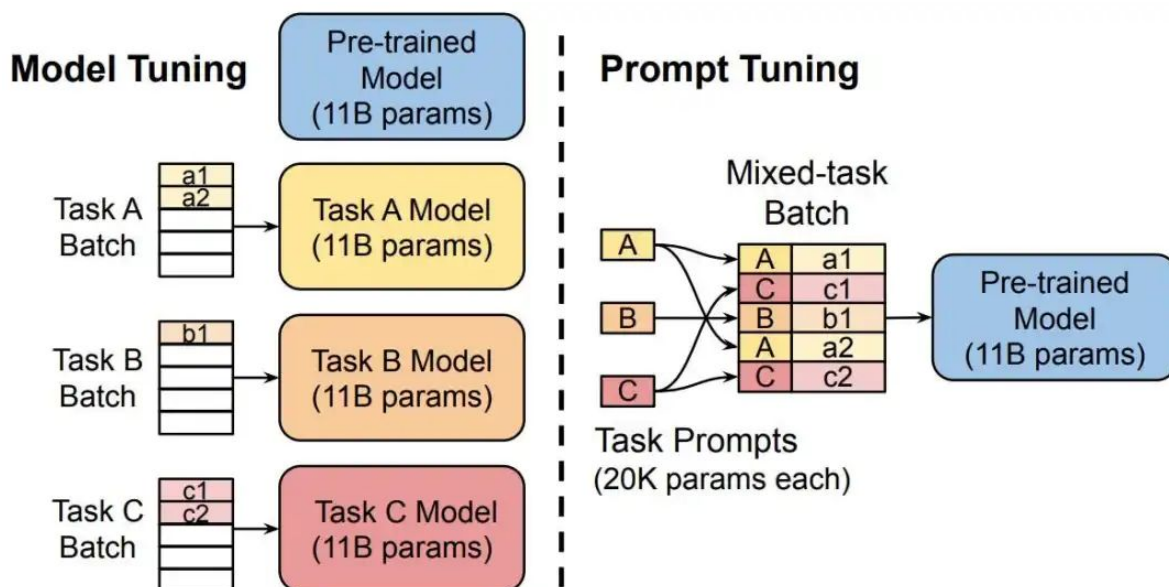


方式一：Prompt-tuning


1、什么是Prompt-tuning?

Prompt-tuning通过修改输入文本的提示 (Prompt) 来引导模型生成符合特定任务或情境的输出，而无需对模型的全量参数进行微调。

这种方法利用了预训练语言模型 (PLM) 在零样本或少样本学习中的强大能力，通过修改输入提示来激活模型内部的相关知识和能力。




核心原理：PLM (预训练模型) 不变，W (模型的权重) 不变，X (模型输入) 改变。




2、如何进行Prompt-tuning?

小模型适配下游任务

设计任务相关提示模板，并微调提示嵌入以引导预训练模型适应特定任务。仅需微调少量提示嵌入 (Prompt Embeddings)，而非整个模型参数。



1. 设计提示模板：
 - 模板中应包含任务描述、输入文本占位符、输出格式要求等元素。
2. 准备数据集：
 - 数据集应包括输入文本、真实标签（对于监督学习任务）或预期输出格式（对于生成任务）。
3. 微调提示嵌入：
 - 在预训练模型的输入层添加提示嵌入层，使用数据集对模型进行训练，特别是微调提示嵌入。




方式二：Prefix-tuning


1、什么是Prefix-tuning?

Prefix-tuning是Prompt-tuning的一种变体，它通过在输入文本前添加一段可学习的“前缀”来指导模型完成任务。

这个前缀与输入序列一起作为注意力机制的输入，从而影响模型对输入序列的理解和表示。由于前缀是可学习的，它可以在微调过程中根据特定任务进行调整，使得模型能够更好地适应新的领域或任务。



核心原理：PLM（预训练模型）不变， W （模型的权重）不变， X （模型输入）不变，增加 W' （前缀嵌入的权重）。



2、如何进行Prefix-tuning?

在Transformer中适配下游任务


在Transformer模型的输入层或各层输入前添加可学习的前缀嵌入，并通过训练这些前缀嵌入来优化模型在特定任务上的表现。

1. 初始化前缀嵌入
 - 在Transformer模型的输入层之前，初始化一个固定长度的前缀嵌入矩阵。
2. 将前缀嵌入与输入序列拼接

- 将初始化好的前缀嵌入与原始输入序列的词嵌入进行拼接，形成新的输入表示。这个新的输入表示将作为Transformer模型各层的输入。

3. 训练模型

- 在训练过程中，模型会根据输入序列（包括前缀嵌入）和标签数据进行学习。通过反向传播算法，模型会更新前缀嵌入的参数。



方式三：LoRA


1、什么是LoRA?

LoRA (Low-Rank Adaptation) 通过分解预训练模型中的部分权重矩阵为低秩矩阵，并仅微调这些低秩矩阵的少量参数来适应新任务。


对于预训练权重矩阵 $W_0 \in \mathbb{R}^{d \times d}$ ，LoRA限制了其更新方式，即将全参微调的增量参数矩阵 ΔW 表示为两个参数量更小的矩阵 A 、 B ，即 $\Delta W = AB$ 。

其中， $B \in \mathbb{R}^{d \times r}$ 和 $A \in \mathbb{R}^{r \times d}$ 为LoRA低秩适应的权重矩阵，秩 r 远小于 d 。



Weight update in regular finetuning



Weight update in LoRA



核心原理：W（模型的权重）不变，X（模型输入）不变，分解 ΔW （分解为两个低秩矩阵A、B）。



$$Y = (W + \Delta W)X = (W + AB)X$$

W 不变，训练低维模型 A, B

2、如何进行LoRA微调？

在冻结预训练模型权重的基础上，通过优化算法训练低秩矩阵A和B以近似增量参数，最小化下游任务损失，从而实现高效的模型微调。


1. 设置LoRA模块

- 在预训练模型的基础上，添加LoRA模块。LoRA模块通常包含两个参数量较少的矩阵A和B，它们的乘积用于近似全参数微调中的增量参数。
- 初始化矩阵A和B，通常使用高斯函数进行初始化，以确保训练开始时LoRA的旁路（即BA）为0，从而与全参数微调有相同的起始点。


2. 训练LoRA模块

- 在训练过程中，冻结预训练模型的权重，仅训练LoRA模块中的矩阵A和B。
- 通过优化算法（如Adam）更新矩阵A和B的参数，以最小化下游任务的损失函数。

Low Rank Adaptation (LoRA) Overview



LLaMA-Factory通过集成LoRA微调方法，为大型语言模型提供高效、低成本的微调方案，支持多模型、多算法和实时监控，仅训练低秩矩阵实现快速适应新任务。



LLaMA-Factory

Easy and Efficient LLM Fine-Tuning

LoRA参数主要包括秩（lora_rank，影响性能和训练时间）、缩放系数（lora_alpha，确保训练稳定）和Dropout系数（lora_dropout，防止过拟合），它们共同影响模型微调的效果和效率。

LoRA 参数设置

LoRA 秩: 8 (LoRA 矩阵的秩大小)

LoRA 缩放系数: 16 (LoRA 缩放系数大小)

LoRA 随机丢弃: 0 (LoRA 权重随机丢弃的概率)

LoRA+ 学习率比例: 0 (LoRA+ 中 B 矩阵的学习率倍数)

在现有的适配器上创建一个随机初始化后的新适配器。 [新建适配器]

对 LoRA 层使用稳定缩放方法。
☒ 使用 rslo

使用权重分解的 LoRA。
☐ 使用 DoRA

使用 PiSSA 方法。
☐ 使用 PiSSA

LoRA 作用模块 (非必填)
应用 LoRA 的模块名称。使用英文逗号分隔多个名称。

附加模块 (非必填)
除 LoRA 层以外的可训练模块名称。使用英文逗号分隔多个名称。

1. 秩 (Rank)

- 参数名称: `lora_rank`
- 描述: 秩是LoRA中最重要的参数之一，它决定了低秩矩阵的维度。
- 常用值: 对于小型数据集或简单任务，秩可以设置为1或2；对于更复杂的任务，秩可能需要设置为4、8或更高。


2. 缩放系数 (Alpha)

- 参数名称: `lora_alpha`
- 描述: 缩放系数用于在训练开始时对低秩矩阵的更新进行缩放。
- 常用值: 缩放系数的具体值取决于秩的大小和任务的复杂度。

3. Dropout系数

- 参数名称: `lora_dropout`
- 描述: Dropout系数决定了在训练过程中随机丢弃低秩矩阵中元素的概率。
- 常用值: Dropout系数的常用值范围在0到1之间。

Forward pass with
updated model



```
1  # LoRA Hyperparameters
2  lora_r = 8
3  lora_alpha = 16
4  lora_dropout = 0.05
5  lora_query = True
6  lora_key = False
7  lora_value = True
8  lora_projection = False
9  lora_mlp = False
10 lora_head = False
```