

大型语言模型初学者指南

第一部分

供稿人: 安娜马莱·
乔克林加姆·安库
尔·帕特尔
沙尚克·维尔马
蒂芙尼·杨



目录

Preface3

Glossary5

Introduction to LLMs8

What Are Large Language Models (LLMs)?8

Foundation Language Models vs. Fine-Tuned Language Models11

Evolution of Large Language Models11

Neural Networks12

Transformers14

How Enterprises Can Benefit From Using Large Language Models20

Challenges of Large Language Models21

Ways to Build LLMs21

How to Evaluate LLMs22

Notable Companies in the LLM Field23

Popular Startup-developed LLM Apps23

前言

几千年来，语言一直是人类社会不可或缺的一部分。一个长期流行的理论，喉头下降理论或LDT，表明语音和语言可能在大约20万或30万年前进化，而最新的研究表明，它可能发生得更早。

不管它最初出现在什么时候，语言仍然是人类交流的基石。在今天的数字时代，信息技术扮演了更重要的角色，在这个时代，前所未有的一部分人可以通过文本和语音在全球范围内进行交流。

全球每天发送和接收3473亿封电子邮件，50亿人(占全球总人口的63%)发送和接收短信，这一事实进一步证明了这一点。

因此，语言已经成为一个巨大的信息宝库，可以帮助企业提取有价值的见解，识别趋势，并做出明智的决定。例如，企业可以分析客户评论等文本，以确定其产品的最畅销功能，并调整其未来的产品开发。

同样，与语言分析相反，语言生产也正在成为企业越来越重要的工具。例如，创建博客帖子可以帮助企业将品牌知名度提高到前所未有的程度，而撰写电子邮件可以帮助他们以无与伦比的速度吸引新的利益相关者或合作伙伴。

然而，语言分析和生产都是耗时的过程，会分散员工和决策者对更重要任务的注意力。例如，领导者经常需要筛选大量的文本，以便做出明智的决策，而不是根据提取的关键信息做出决策。

企业可以通过使用大型语言模型(LLM)来完成与语言相关的任务，从而最大限度地减少这些和其他问题，例如人为错误的风险。LLMs可以帮助企业加快并在很大程度上自动化与语言生产和分析相关的工作，节省宝贵的时间和资源，同时提高准确性和效率。

与以前的解决方案(如基于规则的系统)不同，LLM非常灵活，可以轻松适应各种与语言相关的任务，如生成内容或总结法律文档。

本书的目标是帮助企业理解是什么使 LLM 与以前的解决方案相比如此具有突破性，以及他们如何从采用或开发它们中受益。它还旨在通过概述 LLM 开发、培训和部署的最关键步骤来帮助企业取得领先。

为了实现这些目标，本书分为三个部分：

- 第 1 部分定义了 LLM，并概述了这些年来使其成为可能的技术和方法的进步。它也处理更实际的话题，例如企业如何发展他们自己的 LLM 和 LLM 领域最著名的公司。这应该有助于企业理解采用 LLM 如何能够释放前沿的可能性并革新他们的运营。
- 第 2 部分讨论了 LLM 在企业中的五个主要用例，包括内容生成、摘要和聊天机器人支持。每个用例都以现实生活中的应用程序和案例研究为例，以展示 LLM 如何解决实际问题并帮助企业实现特定目标。
- 第 3 部分是对想要构建、培训和部署自己的 LLM 的企业的实用指南。它概述了必要的先决条件以及不同开发和部署方法之间可能的权衡。ML 工程师和数据科学家可以在整个 LLM 开发过程中以此为参考。

希望这将激励尚未采用或开发自己的物流管理系统的企业尽快这样做，以便获得竞争优势并提供新的 SOTA 服务或产品。和往常一样，最大的好处将留给早期采用者或真正有远见的创新者。

词汇表

深度学习系统	依靠具有许多隐藏层的神经网络来学习复杂模式的系统。
生成人工智能	人工智能程序可以生成新的内容，如文本、图像和音频，而不仅仅是分析它。
大型语言模型 (LLM)	识别、总结、翻译、预测和生成文本和其他内容的语言模型。它们被称为大型，因为它们是在大量数据上训练的，并且有许多参数，流行的 LLM 达到数千亿个参数。
自然语言处理	计算机程序理解和生成的能力 自然语言的文本。
长短期记忆神经网络 (LSTM)	一种特殊类型的 rnn，具有更复杂的小区模块，允许它保留了更多的过去的输入。
自然语言生成 (NLG)	自然语言处理的一部分，指计算机程序能够生成类似人类的文本。
自然语言理解 (NLU)	自然语言处理的一部分，指计算机程序能够理解类似人类的文本。
神经网络	一种机器学习算法，其中参数被组织成连续的层。神经网络的学习过程受人脑的启发。与人类非常相似，神经网络通过表征学习“学习”重要特征，并且比大多数其他机器学习方法需要更少的人类参与。
感知人工智能	可以处理和分析但不能生成数据的 AI 程序，主要在 2020 年之前开发。
递归神经网络 (RNN)	按顺序处理数据的神经网络，可以记住过去的输入。

条款

描述

基于规则的系统

一种依靠人工规则来处理数据的系统。

传统机器学习

传统的机器学习使用统计方法，根据大型标注语料库绘制单词或其他标记的概率分布。它更少依赖规则，更多依赖数据。

变压器

一种神经网络体系结构，设计用于非顺序地处理顺序数据。

结构数据

本质上是定量的数据，如电话号码，可以很容易地标准化并调整为 ML 算法可以快速处理的预定义格式。

非结构化数据

本质上属于定性的数据，如客户评论，难以标准化。此类数据在使用前以其原始格式存储，如 PDF 文件。

微调

一种迁移学习方法，用于提高选定下游任务或数据集的模型性能。当目标任务类似于预训练任务，并且涉及复制 PLM 的权重并根据期望的任务或数据对其进行调整时，使用该方法。

用户化

一种通过修改 PLM 的一个或几个选定参数而不是更新整个模型来提高模型性能的方法。它包括使用参数有效技术 (PEFT)。

参数高效技术 (PEFT)

像即时学习、LoRa 和适配器调整这样的技术

它允许研究人员为下游任务或数据集定制 PLM，同时保留和利用 PLM 的现有知识。这些技术在模型定制期间使用，并且允许更快的训练和通常更准确的预测。

迅速学习

这是两种 PEFT 技术的总称，即即时调优和 p-tuning，它通过在离散或真实令牌嵌入中插入虚拟令牌嵌入来帮助定制模型。

适配器调谐

一种 PEFT 技术，涉及在现有 PLM 层之间添加称为适配器的轻量级前馈层，并在定制期间仅更新其权重，同时保持原始 PLM 权重不变。

开放领域问答

回答各种不同领域的问题，比如

法律、医疗和金融，而不仅仅是一个领域。

抽取式问题回答

通过从现有文本或数据库中提取答案来回答问题。

条款

描述

吞吐量

模型效率和速度的度量。它指的是模型在预定义的时间范围内可以处理或生成的数据量或预测数。

潜伏

模型处理输入和生成输出所需的时间。

数据就绪

基于数据数量、结构和质量等因素的数据在培训中的适用性。

LLMs 简介

大型语言模型是一种人工智能 (AI) 系统，能够根据它从大量数据中学习的模式和关系生成类似人类的文本。大型语言模型使用一种称为深度学习的机器学习技术来分析和处理大型数据集，如书籍、文章和网页。

大型语言模型在自然语言处理和人工智能领域释放了无数前所未有的可能性。这在 2020 年 OpenAI 的 GPT-3 的发布中得到了最明显的证明，这是当时开发的最大的语言模型。

这些模型旨在理解文本的上下文和含义，并可以生成语法正确、语义相关的文本。他们可以接受多种任务的训练，包括语言翻译、摘要、问答和文本补全。

GPT-3 清楚地表明，大规模模型可以准确地执行从文本摘要到文本生成的一系列前所未闻的 NLP 任务。它还表明，LLM 可以生成与人类创建的文本几乎没有区别的输出生，同时在最少的人工干预下自行学习。

这是对早期主要基于规则的模型的巨大改进，早期的模型既不能自主学习，也不能成功解决未经训练的任务。因此，毫不奇怪，许多其他企业和初创公司很快开始开发自己的 LLM 或采用现有的 LLM，以加速运营、降低成本和简化工作流程。

第 1 部分旨在为任何考虑构建或采用自己的 LLM 的企业提供坚实的介绍和基础。

什么是大型语言模型？

大型语言模型 (LLM) 是深度学习算法，可以基于在大型数据集上训练期间获得的知识来识别、提取、总结、预测和生成文本。

它们也是一种叫做语言模型的更通用技术的子集。所有语言模型都有一个共同点：它们可以处理和生成听起来像自然语言的文本。这被称为执行与自然语言处理 (NLP) 相关的任务。

尽管所有语言模型都可以执行 NLP 任务，但它们在其他特征上有所不同，比如它们的大小。与其他模型不同，LLM 被认为是大尺寸的，原因有两个：

- 1. 他们使用大量数据进行训练。
- 2. 它们包括大量可学习的参数(即，帮助模型对新的或从未见过的数据执行任务的训练数据的底层结构的表示)。


Table 1 展示了两个大型语言模型，MT-NLG 和 GPT-3 达芬奇，以帮助澄清什么是当代的标准来看算是大的。

表 1。 NLG 山和 GPT-3 的比较

大型语言模型	参数数量	训练数据中的令牌数
英伟达模型:威震天-图灵自然语言生成模型 (MT-NLG)	5300 亿	2700 亿
开放 AI 模型:GPT-3 达芬奇模型	1750 亿	4990 亿

由于模型的质量在很大程度上取决于模型的大小和训练数据的大小，较大的语言模型通常比较小的语言模型生成更准确和复杂的响应。

图一。 GPT-3 生成的答案。



然而，大型语言模型的性能不仅仅取决于模型大小或数据量。数据的质量也很重要。

例如，在同行评审的研究论文或出版的小说上接受培训的法学硕士通常比在社交媒体帖子、博客评论或其他未评审内容上接受培训的法学硕士表现更好。像用户生成的内容这样的低质量数据可能会导致各种各样的问题，比如模型使用俚语、学习不正确的单词拼写等等。

此外，模型需要非常多样的数据来执行各种 NLP 任务。但是，如果该模型旨在特别擅长解决一组特定的任务，则使用更相关和更窄的数据集对其进行微调。通过这样做，基础语言模型从一个擅长在广泛的领域中执行各种 NLP 任务的模型转变为一个精调的模型，该模型专门在狭窄范围的领域中执行任务。

基础语言模型与微调语言模型

基础语言模型，比如前面提到的 MT-NLG 和 GPT-3，是在讨论 LLM 时经常提到的。他们接受了大量数据的训练，可以执行各种各样的 NLP 任务，从回答问题和生成书籍摘要到完成和翻译句子。

由于它们的规模，基础模型可以很好地执行，即使它们只有很少的特定领域的的数据。他们在各种任务中都有很好的总体表现，但可能不擅长执行任何一项特定的任务。

另一方面，微调语言模型是从基础 LLM 派生的大型语言模型。它们是为特定的用例或领域定制的，因此，在执行更专业的任务方面变得更好。

除了微调模型可以比基础模型更好地执行特定任务这一事实之外，它们最大的优势是它们更轻，并且通常更容易训练。但是我们如何为特定的目标微调一个基础模型呢？

目前，最流行的方法是使用参数高效的定制技术来定制模型，比如 p-tuning、prompt tuning、adapters 等等。与微调整个模型相比，定制花费的时间和成本要少得多，尽管它可能会导致比其他方法稍差的性能。自定义方法将在中进一步讨论 [Part 3](#)。

大型语言模型的发展

人工智能系统历史上是关于处理和分析数据，而不是产生数据。他们更倾向于感知和理解我们周围的世界，而不是产生新的信息。这一区别标志着感知型和生成型人工智能之间的主要区别，后者自 2020 年左右开始变得越来越普遍，或者在公司开始采用变压器模型并大规模开发越来越强大的 LLM 之后。

大型语言模型的出现进一步推动了 NLP 模型设计、训练和使用方式的革命性范式转变。为了真正理解这一点，比较大型语言模型和以前的 NLP 模型以及它们是如何工作的可能是有帮助的。出于这个目的，让我们简单地探讨一下自然语言处理历史上的三个阶段：变形金刚之前的自然语言处理、变形金刚自然语言处理和 LLM 自然语言处理。

1. 变形金刚之前的 NLP 主要是由依赖于人制定的规则而不是机器学习算法来执行 NLP 任务的模型来标记的。这使得它们适用于不需要太多规则的简单任务，如文本分类，但不适合更复杂的任务，如机器翻译。基于规则的模型在边缘情况下也表现不佳，因为它们无法对没有明确规则的前所未见的数据进行准确的预测或分类。这个问题在某种程度上可以用简单的神经网络来解决，如在这一时期后期发展起来的 RNNs 和 LSTMs。rnn 和 LSTMs 可以在一定程度上记忆过去的的数据，从而提供依赖于上下文的预测

分类。然而，rnn 和 LSTMs 不能对长时间的文本进行预测，这限制了它们的有效性。

2. 2017 年，变压器架构的兴起推动了变压器 NLP 的发展。Transformers 可以比当时流行的 RNNs 和 LSTMs 更好地概括，捕捉更多的上下文，并一次处理更多的数据。这些改进使 NLP 模型能够理解更长的数据序列，并执行更广泛的任務。然而，从今天的角度来看，这一时期开发的模型能力有限，主要是因为普遍缺乏大规模数据集和足够的计算资源。它们也主要在该领域的研究人员和专家中引起了注意，但不是普通公众，因为它们不够用户友好，也不够准确，无法商业化。
3. LLM NLP 主要是由 OpenAI 的 GPT-3 在 2020 年的发射启动的。像 GPT-3 这样的大型语言模型是在大量数据的基础上训练的，与以前的模型相比，这允许它们产生更准确和更全面的 NLP 响应。这开启了许多新的可能性，并使我们更接近实现许多人认为的“真正的”人工智能。此外，LLMs 使得非技术用户更容易使用 NLP 模型，他们现在可以通过使用自然语言提示来解决各种 NLP 任务。NLP 技术最终被大众化了。

从一种方法到另一种方法的转变在很大程度上是由相关技术和方法的进步推动的，如神经网络、注意力机制和变压器的出现以及无监督和自我监督学习领域的发展。以下部分将简要解释这些概念，因为理解它们对于真正理解 LLM 如何工作以及如何从头构建新的 LLM 至关重要。

神经网络

神经网络 (NNs) 是模仿人脑的松散的机器学习算法。像生物人脑一样，人工神经网络由神经元组成，也称为节点，负责所有模型功能，从处理输入到生成输出。

神经元被进一步组织成层，垂直堆叠的 NNs 组件，执行与输入和输出序列相关的特定任务。

每个神经网络至少有三层：

- 输入层接受数据并将其传递给网络的其余部分。
- 隐藏层或多个隐藏层执行特定的功能，使神经网络的最终输出成为可能。这些功能可以包括识别或分类数据、生成新数据以及其他功能，具体取决于所讨论的特定 NLP 任务。
- 输出层基于输入生成预测或分类。

当 LLM 最初被开发时，它们基于具有更少层的更简单的 NN 架构，主要是递归神经网络 (RNNs) 和长短期记忆网络 (LSTMs)。与其他神经网络不同，RNNs 和 LSTMs 可以考虑单词之间的上下文、位置和关系，即使它们在数据序列中相距很远。简而言之，这意味着他们可以在生成输出时记住并考虑过去的信息，从而为许多 NLP 任务提供更准确的解决方案，特别是情感分析和文本分类。

与传统的基于规则的系统相比，像 RNNs 和 LSTMs 这样的神经网络的最大优势是它们能够在很少或没有人类参与的情况下自行学习。他们分析数据以创建自己的规则，而不是先学习规则，然后再应用于数据。这也被称为表征学习，受人类学习过程的启发。

表示或特征是神经网络可以从数据中提取的隐藏模式。为了举例说明这一点，让我们假设我们正在一个数据集上训练一个基于神经网络的模型，该数据集包含以下令牌：

“猫” “猫” “狗” “狗”

在分析这些表征之后，该模型可以识别一种表示，人们可以将其公式化为：

复数名词有后缀 “-s”

然后，模型将提取此表示，并将其应用于数据分布遵循训练数据分布的新场景或边缘场景。例如，可以假设模型将正确地将像“椅子”或“桌子”这样的标记分类为复数或单数，即使它以前没有遇到过它们。一旦遇到不符合提取的表示的不规则名词，模型将更新其参数以反映新的表示，例如：


复数名词后接复数动词。

这种方法使基于神经网络的模型能够比基于规则的系统更好地概括，并成功地执行更广泛的任務。

然而，他们提取表征的能力在很大程度上取决于神经元的数量和组成网络的层数。神经网络拥有的神经元越多，它们能够提取的复杂表示就越多。这就是为什么今天，大多数大型语言模型使用具有多个隐藏层的深度学习神经网络，从而拥有更多数量的神经元。

Figure 2 显示了单层神经网络和深度学习神经网络的并排比较。

图二。 单层与深度学习神经网络的比较



虽然这在今天似乎是一个显而易见的选择，但考虑到在硬件发展到能够处理大量工作负载之前，开发深度神经网络没有意义。这只有在大约 1999 年之后才有可能，当时 NVIDIA 向更广泛的市场推出了“世界上第一个 GPU”，或图形处理单元，或者更准确地说，在 2012 年名为 AlexNet 的 CNN 大获成功将其用于深度学习之后。

GPU 具有高度可并行化的架构，这使得今天看到的深度学习系统能够快速发展。在其他进步中，GPU 的出现带来了一种新型神经网络的发展，这将彻底改变 NLP 领域: 变压器。

变形金刚(电影名)

虽然 RNNs 和 LSTMs 有其优势，特别是与传统模型相比，但它们也有一些限制，使它们不适合更复杂的 NLP 任务，如机器翻译。它们的主要限制是无法处理较长的数据序列，因此无法考虑输入序列的整体上下文。因为 LSTMs 和 rnn 不能很好地处理太多的上下文，它们的输出容易不准确或无意义。随着被称为变压器的新的特殊神经网络的出现，这一挑战和其他挑战已经在很大程度上被克服。

2017 年，瓦斯瓦尼等人在一篇题为“你只需要注意力”的论文中首次介绍了变形金刚。标题暗示了注意力机制，这将成为变形金刚的关键组成部分。

“我们提出了一种新的简单的网络结构，转换器，完全基于注意力机制，完全免除了递归和卷积。”- 瓦斯瓦尼等人。艾尔，“你需要的只是关注”

该论文提出，注意机制将使递归和卷积在顺序数据方面过时，并使转换器比 rnn 和 CNN 更适合于机器翻译。这个预言将很快成为现实，因为变形金刚将继续成为主导架构，不仅用于机器翻译，而且用于所有 NLP 任务。

注意机制通过允许模型在处理输入时选择性地注意输入的某些部分，解决了上下文处理不充分的问题。现在，模型可以专注于与特定任务相关的最重要的表征，而不必一次捕获整个上下文。

为了演示这一点，让我们假设所需的模型是基于 transformer 的模型，用于预测以下输入句子的下一个单词：

玛丽有一只小羊羔。

注意机制——或者更确切地说，是基于注意机制的自我注意层——将首先计算我们输入的每个单词的注意权重。注意力权重代表每一个标记的重要性，所以一个标记被分配的权重越大，它就被认为越重要。例如，注意力机制可能给予单词“lamb”比单词“a”更大的权重，因为它可能对最终输出有更大的影响。

然后，该模型将使用这些权重在生成输出时动态地强调或淡化每个单词。如果假设最大权重被分配给单词“lamb”，则该模型可以产生如下延续：

“谁的羊毛洁白如雪”

为了确定每个标记的重要性，自我关注层检查它与序列中其他标记的关系：

1. 如果一个令牌与其他令牌在正在执行的任务方面有许多相关关系，则该令牌被认为是重要的，并且可能比同一序列中的其他令牌更重要。
2. 如果一个令牌与其他令牌没有太多关系，或者如果它们与特定任务无关，则该令牌被认为不太重要或完全不重要。这意味着模型在生成输出时实际上会忽略它。

因此，通过使模型更有效地处理上下文，注意力机制允许它们比基于 RNNs 和 LSTMs 的模型产生更准确的输出。同时，这种新的数据处理方法还允许基于变压器的模型比基于 RNN 和 LSTM 的模型更快地生成输出。

LSTMs 和 rnn 需要更多时间来生成输出，因为它们按顺序处理输入。为了阐明这意味着什么，让我们探索 LSTMs 将如何处理我们的原始输入句子：

玛丽有一只小羊羔。

由于 LSTMs 是按顺序处理数据的，它们需要一次处理我们序列中的一个单词：Mary、had、a、little、lamb。这大大降低了推断的速度，尤其是对于较长的数据序列。例如，想象一下 LSTMs 和 RNNs 处理一个维基百科页面需要多长时间。太久了。

另一方面，转换器并行处理数据，这意味着它们一次“读取”所有输入令牌，而不是一次处理一个。这也意味着它们能够比 LSTMs 和 rnn 更快地执行 NLP 任务。

然而，尽管速度慢，顺序数据处理有一个很大的优势。通过一次处理一个单词，LSTMs 和 RNNs 总是能够分辨出哪个单词先出现，哪个后出现，等等。他们知道输入序列的单词顺序，因为他们使用相同的顺序来处理它。相反，转换器最初并不“知道”原始的单词顺序，因为它们是不按顺序处理数据的。虽然乍一看这似乎只是一个小问题，但分析下面的句子可能会说明其他问题：

1. 玛丽有一只小羊羔。

2. 一只小羊羔生了玛丽。


3. 玛丽有一只小羊羔。

句子(2)显示了词序的微小变化如何扭曲了预期的意思，而句子(3)则说明了一个更大的问题——词序的变化如何导致完全无意义和语法错误的变化。

为了克服这一挑战，变压器使用位置编码来帮助它们保留位置信息。位置编码是与每个标记相关联的附加输入或向量。它们可以是固定的，也可以是可训练的，这取决于模型是否希望在训练过程中对它们进行改进。

图 3。 LSTM 中的顺序数据处理

来源:关注是你所需要的



研究人员和公司将很快开始实施这些新机制，并建立新的基于变压器的模型，谷歌将在 2018 年发布其著名的 BERT。

伯特

Google 的 BERT(来自 Transformers 的双向编码器表示)是首批基于 transformer 的语言模型之一。这是一个掩蔽语言模型 (MLM)，这意味着它是在包含掩蔽标记的句子训练的。该模型需要通过考虑其周围环境来预测被屏蔽的令牌。为了说明这一点，让我们设想一个模型被给予以下输入句子：

“我有一个面具。”

伯特的任务是预测被屏蔽的单词“有”它通过分析两边的记号来做到这一点，即“I”、“a”和“mask”。这使得它是双向的，并且比以前的语言模型更准确，以前的语言模型只能考虑屏蔽标记左边的上下文。在这种情况下，单向模型在预测屏蔽词时将仅考虑词“I”，这提供了很少的上下文。单向模型产生正确预测的机会更小。

BERT 是第一个展示双向如何模拟 NLP 任务性能 的模型。它被用于各种目的，包括通过更好地理解查询的上下文和含义来提高谷歌搜索结果的准确性。

其他大型语言模型

Google 的 BERT 和该领域的新进展启发了其他公司开始构建他们自己的大型语言模型。在下表中，我们列出了在 2020 年 6 月发布的真正开创性的 GPT-3 之前开发的一些模型。

Table 2 显示了后续 LLM 版本的时间表。

表二。大型语言模型发布时间表

模型	公司	年	简要描述
GPT-2	OpenAI 公司	2019	基于 transformer 的语言模型，旨在生成类似人类的文本并执行各种 NLP 任务，包括语言翻译、摘要和问题回答。
罗伯塔	脸谱网	2019	一种基于 BERT 的模型，旨在通过在更大的数据集上训练模型并使用更有效的训练方法来提高 NLP 任务的性能。
德伯塔	微软	2020	一种基于 BERT 的模型，旨在通过分离模型的编码器和解码器组件来提高 NLP 任务的性能。
GPT-3	OpenAI 公司	2020	GPT-2 的升级模型在更大规模的数据集上进行训练，能够生成更高质量的输出。

通过证明 LLMs 可以用于少量学习和 excel 而无需“大规模特定任务数据收集或模型参数更新”，GPT-3 将激励公司建立更大的模型，如具有 5300 亿参数的威震天-图灵自然语言生成，5400 亿参数的 PaLM 和具有令人印象深刻的 1.75 万亿参数的 WuDao 2.0。

无监督和自我监督学习

BERT 不是革命性的，不仅因为它是一个双向模型，还因为它是使用无监督学习训练的。无监督学习是指机器学习算法在没有人工干预的情况下，在未标记的数据集中发现模式。在 BERT 的案例中，模型必须在训练期间自己从简单语言的维基百科页面中提取模式。这通常被认为是最纯粹的人工智能。

无监督学习模型使用反馈循环来学习和提高它们的性能。这包括获得关于预测或分类是对还是错的反馈，模型使用这些反馈来指导未来的决策。

反馈循环是一些人区分无监督学习和自我监督学习的原因。自我监督学习模型没有反馈回路，而是使用监督信号

在培训期间获得反馈。这些信号是根据数据自动生成的，无需人工注释。

与监督学习相比，无监督和自我监督学习技术都有一个关键优势：它们依靠模型自己创建标签和提取特征，而不需要人工干预。这有助于公司训练模型，而无需耗时的数据标记过程或提供对模型输出的人工反馈。

自我监督学习目前是预先训练大型语言模型的主要方法，并且经常被推荐给想要建立自己的模型的企业。

GPT Vs 伯特的优势

GPT(生成式预训练转换器)和BERT(来自转换器的双向编码器表示)都是非常先进和广泛使用的自然语言处理(NLP)模型。然而，它们在架构和用例上有所不同。

GPT是一个生成模型，它被训练成在给定前一个单词的情况下预测句子中的下一个单词。这种预先训练使GPT能够从头开始生成连贯和流畅的句子，使其成为语言生成任务的理想选择，如文本完成、摘要和问题回答。

与众不同的是，BERT是一个判别模型，它被训练成将句子或标记分类成不同的类别，例如情感分析、命名实体识别和文本分类。它是一个双向模型，同时考虑句子的左上下文和右上下文来理解单词的意思，这使得它对于情感分析和问题回答等任务非常有效。

在架构方面，GPT使用单向变压器，而伯特使用双向变压器。这意味着GPT在进行预测时只能考虑单词的左上下文，而伯特同时考虑左上下文和右上下文。

GPT和伯特都是强大的模型，彻底改变了自然语言处理领域。他们的选择取决于手头的具体任务，研究人员和从业人员通常使用两种模型的组合来实现最佳结果。

企业如何从使用大型语言模型中获益

企业每天都需要处理与语言相关的任务。这包括更明显的文本任务，如编写电子邮件或生成内容，但也包括分析患者数据以了解健康风险或为客户提供陪伴等任务。所有这些任务都可以使用大型语言模型实现自动化。

模型，或由大型语言模型驱动的应用程序，可以帮助企业加速许多复杂的任务，并且通常比人工代理更精确地执行它们。例如，科技企业可以使用它们更快地编写代码，而银行可以使用它们在分析文档以发现欺诈迹象时最大限度地降低人为错误的风险。

自动化复杂但通常繁琐的任务进一步允许员工专注于更重要的任务，从而更快地取得进展。例如，我们将在第 2 部分中看到医疗保健企业如何使用 LLMs 来生成合成临床数据，并使用它来加速医学研究。

LLM 可以在许多其他方面使企业受益，这取决于如何使用它们。一些用例，如基于 LLM 的情绪分析，为他们提供了关于受众的更深入的见解，而客户流失预测则允许他们在客户即将离开公司时鼓励他们留在公司。此外，企业可以使用 LLM 来提供新的基于对话的服务，例如专门的人工智能伴侣。

大型语言模型的挑战

想要开始使用大型语言模型或者由大型语言模型支持的应用程序的企业应该注意一些常见的与 LLM 相关的陷阱。下面是一些通用的方法，不管模型是定制的、微调的还是从头构建的，这些方法都是适用的。

1. 大型语言模型容易受到对立例子的影响。对立的例子是专门用来愚弄模型犯错误的输入。这可能会引发安全问题，尤其是对医疗保健或金融等敏感行业的企业而言。
2. 大型语言模型可能缺乏可解释性。可解释性是指解释和预测模型决策的能力。可解释性低的模型可能很难进行故障诊断和评估，因为可能不清楚他们是如何做出决策的，或者这些决策有多准确或公正。这在高风险用例(如欺诈检测)和需要高度透明的行业(如医疗保健和金融)中尤其成问题。
3. 大型语言模型可能提供非定制的、通用的答案。因此，LLM 可能并不总是对人类输入做出很好的响应，或者理解其背后的意图。这可以通过人类反馈强化学习(RLHF)等技术来改善，这种技术可以帮助模型根据正面或负面的人类反馈随着时间的推移提高性能。即便如此，LLM 有时也能重现他们在训练中看到的文本数据。仅从道德角度来看，这是有问题的，但也可能使企业面临不必要的版权和法律问题。
4. 使用大型语言模型会引发伦理问题。企业是否应该将 LLM 用于重要的决策任务是值得怀疑的，例如根据收集的简历决定哪个候选人最合格，尤其是在没有人监督的情况下。此外，应该评估使用 LLM 完成通常由人类(主要是白领工人)执行的任务是否道德。
5. 大型语言模型可能会产生不适当和有害的内容。在这一点上，企业应该记住，LLM 通常是在大型互联网文本语料库上接受培训的，这可能使他们容易产生有毒、有偏见以及其他不适当和有害的内容。

想要从头开始构建专有 LLM 的企业还需要解决额外的挑战，比如他们是否有足够的计算能力、存储、数据集、专业知识和财务资源来开发、实现和维护模型。

构建 LLM 的方法

从头开始构建大型语言模型并不总是有意义的，尤其是对于核心业务与 AI 或 NLP 技术无关的企业。由于这一过程非常耗时，而且会耗尽资源，因此大多数企业更有可能选择定制现有模型来满足自己的需求。

定制现有基础模型(也称为预训练模型或 PLM)通常可分为三个基本步骤:

1. 寻找合适的基础模型(PLM)。这需要考理想模型大小、训练任务和数据集、LLM 提供者等等。
2. 微调模型。基本模型可以在特定语料库上针对特定用例进行微调。例如,基于文本分类的模型可以针对情感分析进行微调,或者使用法律记录进行训练以精通法律术语。
3. 优化模型。可以使用诸如人类反馈强化学习(RLHF)之类的技术来进一步优化模型,其中基于对其预测或分类的正面或负面人类反馈来更新模型。RLHF 似乎特别有前途,部分原因是它被广泛用于流行的 ChatGPT。

或者,企业可以选择仅使用参数高效技术(如适配器和 p-tuning)定制基本模型。当基础模型在类似于所选下游任务的任务上被训练时,定制可以产生特别精确的模型。例如,基本文本分类模型可能是定制情感分析的良好候选,因为这两个任务非常相似。由于受过文本分类训练,该模型可以利用它在训练期间获得的知识来更容易地执行情感分析任务。

如何评价 LLMs

大型语言模型(LLM)使用深度学习技术来分析和生成自然语言。这些模型越来越受欢迎,因为它们能够执行广泛的语言相关任务,如语言翻译、文本摘要和问答。然而,评估 LLMs 的性能并不是一项简单的任务,它需要仔细分析不同的因素,如训练数据、模型大小和推理速度。

评估 LLMs 最关键的因素是所使用的训练数据的质量和数量。训练数据应该是多样化的,并代表目标语言和领域,以确保 LLM 可以有效地学习和概括语言模式。此外,训练数据应该用相关的标签或标记进行注释,以实现监督学习,这是 LLMs 中最常用的方法。

另一个重要因素是模型的大小。通常,较大的模型具有更好的性能,但是它们也需要更多的计算资源来训练和运行。因此,研究人员通常根据具体任务和可用资源,在模型大小和性能之间进行权衡。还值得注意的是,较大的模型往往更容易过度拟合,这可能导致新数据的泛化性能较差。

在评估中还必须使用推理速度,尤其是在现实应用中部署 LLM 时。更快的推理时间是可取的,因为它使 LLM 能够及时有效地处理大量数据。一些技术,例如剪枝、量化和提取,已经被提出来减小 LLMs 的大小并提高其速度。

为了评估 LLM 的性能，研究人员通常使用基准，即针对特定语言相关任务的标准化数据集和评估指标。基准可以在不同的模型和方法之间进行公平的比较，并有助于确定 LLM 的优势和劣势。常见的基准包括 GLUE(通用语言理解评估)、SuperGLUE 和 CoQA(会话式问答)。

LLM 领域的著名公司

2018 年 BERT 的发布，更值得注意的是，2020 年 GPT-3 的发布，促使大型科技公司和较小的创业公司都带着自己的 LLM 和创新的模型开发方法加入了这场竞赛。中列出了在本书出版时开发自己的 LLM 的最著名的公司 Table 3.

表 3。 开发 LLM 的著名公司

公司	法学硕士
OpenAI 公司	GPT-3 达芬奇 (175B)
AI21 实验室	侏罗纪-1-Jumbo (178B)
伊莱瑟雷	GPT-尼欧克斯 (20B)
人类的	蕙环类 LM (52B)
密切配合	Cohere xlarge v20220609 (52.4B)
英伟达/微软	威震天-图灵自然语言生成 (MT-NLG 530B)
微软	图灵自然语言生成 (T-NLG 17B)
谷歌	路径语言模型 (PaLM 540B)
元	开路预应变变压器 (OPT-175B)

其中一些公司允许其他组织访问他们的模型。例如，企业可以为下游任务定制由 OpenAI、Cohere 或 NVIDIA 开发的预训练模式，或者通过 API 将其集成到产品和内部系统中。

受欢迎的初创公司开发的 LLM 应用

OpenAI 的 ChatGPT 是迄今为止开发的最受欢迎的 LLM 驱动的应用程序。据估计，它在推出后的两个月内吸引了超过 1 亿用户，使其成为“历史上增长最快的消费应用”

然而，许多其他创业公司带着他们自己的，通常更专业和商业化的 LLM 驱动的应用程序进入了这个领域。最受欢迎的应用之一是 LLM 驱动的内容生成器，如 Jasper 和 Copy.ai。相比之下，Jasper 自称为超过 10 万个全球团队提供服务，而 Copy.ai 声称自推出以来已吸引了超过 500 万用户。

Figure 4 展示了一个自然语言提示的示例，用户可以在 Copy.ai 中输入该提示来生成博客文章大纲。

图 4。 自然语言提示的结果示例

The screenshot shows a web interface titled "Blog Outline" with a subtitle "2022-11-04 Untitled (2)". In the top right corner, there are buttons for "Create" and "Saved (0)". Below this, there is a "Supercharge" button with a "beta" label and a toggle switch. The main form has two sections: "What is your blog title? Optional" and "What is the blog about?". The title field contains the text "Best GPT-3 Commercial Use Cases In 2022". The topic field contains a list of bullet points: "Quick intro to OpenAI's GPT-3", "Analyzing GPT-3 powered writing apps like Copy.ai, Lex, Jasper, and Frase.io", "OpenAI's GPT-3 Vs GPT-3 Powered Writing Apps (Differences between OpenAI's GPT-3 and product wrappers created around the tech)", and "The future of GPT-3 powered writing apps". To the right of the topic field is a "Close" button. Below the topic field, there is a character count "272/1000". At the bottom of the form, there is a "Choose a tone" section with a dropdown menu currently set to "Professional". A large purple button labeled "Create Content" is at the very bottom.

2022-11-04 Untitled (2)

Blog Outline

Create Saved (0)

Supercharge beta

What is your blog title? Optional

Best GPT-3 Commercial Use Cases In 2022

What is the blog about?

- Quick intro to OpenAI's GPT-3
- Analyzing GPT-3 powered writing apps like Copy.ai, Lex, Jasper, and Frase.io
- OpenAI's GPT-3 Vs GPT-3 Powered Writing Apps (Differences between OpenAI's GPT-3 and product wrappers created around the tech)
- The future of GPT-3 powered writing apps

272/1000

Choose a tone Enter a custom tone or choose a preset tone

Professional

Create Content

其他受欢迎的 LLM 驱动的应用程序包括广受欢迎的语法检查和编写工具 Grammarly 和 GitHub Copilot，这是一个由 Codex 驱动的编码助手，可以帮助开发人员编写和学习代码。

第 2 部分将介绍企业和初创公司利用 LLM 构建专门的内容生成、异常检测、毒性分类和其他高级 NLP 用例的更多方法。它还将提供具体的例子，说明如何进一步定制它们以满足各种行业的需求，如金融、医疗保健和电信，希望激励组织使用 LLM 在各自的行业中释放新的可能性。

通知：注意

本文档仅供参考，不得视为对产品特定功能、条件或质量的保证。NVIDIA Corporation(“NVIDIA”)对本文所含信息的准确性或完整性不做任何明示或暗示的陈述或保证，也不对本文所含的任何错误承担任何责任。NVIDIA 对此类信息的后果或使用不承担任何责任，也不对使用此类信息可能导致的任何侵犯第三方专利或其他权利的行为承担任何责任。本文档并不承诺开发、发布或交付任何材料(定义如下)、代码或功能。

NVIDIA 保留随时对本文档进行更正、修改、增强、改进和任何其他更改的权利，恕不另行通知。客户应在下订单前获取最新的相关信息，并验证这些信息是最新的和完整的。

NVIDIA 产品的销售受订单确认时提供的 NVIDIA 标准销售条款和条件的约束，除非 NVIDIA 授权代表和客户签署的单独销售协议中另有约定(“销售条款”)。NVIDIA 特此明确反对在购买本文档中提及的 NVIDIA 产品时适用任何客户一般条款和条件。本文件不直接或间接形成任何合同义务。

NVIDIA 产品的设计、授权或担保不适用于医疗、军事、飞机、太空或生命支持设备，也不适用于 NVIDIA 产品的故障或失灵可能导致人身伤害、死亡、财产或环境损害的应用。NVIDIA 对在此类设备或应用中包含和/或使用 NVIDIA 产品不承担任何责任，因此此类包含和/或使用风险由客户自行承担。

NVIDIA 不表示或保证基于本文档的产品将适用于任何指定用途。NVIDIA 不一定要对每个产品的所有参数进行测试。客户全权负责评估和确定本文档中包含的任何信息的适用性，确保产品适合客户计划的应用，并对应用进行必要的测试，以避免应用或产品出现故障。客户产品设计中的缺陷可能会影响 NVIDIA 产品的质量和可靠性，并可能导致超出本文档内容的其他或不同的条件和/或要求。NVIDIA 不承担任何违约、损害、成本或问题相关的责任，这些违约、损害、成本或问题可能基于或归因于：(i) 以任何违反本文档的方式使用 NVIDIA 产品，或(ii) 客户产品设计。

根据本文档，不授予任何 NVIDIA 专利权、版权或其他 NVIDIA 知识产权的许可，无论是明示的还是暗示的。NVIDIA 发布的关于第三方产品或服务的信息不构成 NVIDIA 使用此类产品或服务的许可，也不构成其担保或认可。使用这些信息可能需要根据第三方的专利或其他知识产权从第三方获得许可，或者根据 NVIDIA 的专利或其他知识产权从 NVIDIA 获得许可。

只有在事先获得 NVIDIA 书面批准的情况下，才允许复制本文档中的信息，复制时不得改动，并完全遵守所有适用的出口法律和法规，同时附有所有相关条件、限制和通知。

本文档和所有 NVIDIA 设计规范、参考板、文件、图纸、诊断、列表和其他文档(一起或单独作为“材料”)均按“原样”提供 NVIDIA 对这些材料不作任何明示、暗示、法定或其他形式的担保，并明确否认对非侵权性、适销性和特定用途适用性的所有暗示担保。在法律不禁止的范围内，NVIDIA 在任何情况下都不对任何损害负责，包括但不限于任何直接的、间接的、特殊的、偶然的、惩罚性的或后果性的损害，不管是由什么原因引起的，也不管责任理论如何，即使 NVIDIA 已经被告知这种损害的可能性。尽管客户可能因任何原因遭受任何损害，NVIDIA 的总

此处描述的产品对客户的累积责任应根据产品的销售条款进行限制。

商标

NVIDIA、NVIDIA 徽标是 NVIDIA Corporation 在美国和其他国家的商标和/或注册商标。其他公司和产品名称可能是与其相关的各自公司的商标。

版权

2023 英伟达公司。版权所有

